

# Robotika in računalniško zaznavanje (RRZ)

## Iskanje robov in kotov

Danijel Skočaj

Univerza v Ljubljani

Fakulteta za računalništvo in informatiko



Literatura: W. Burger, M. J. Burge (2008).

Digital Image Processing, poglavja 7, 8

v1.0


# Robovi

- Robovi so zelo informativni



# Kaj je rob?


- Robovi so deli slik (slikovni elementi) kjer se lokalna intenziteta bistveno spremeni v določeni smeri




# Odvod zvezne funkcije

- Lokalne spremembe merimo z odvodom:

$$f'(x) = \frac{df}{dx}(x)$$



(a)





(b)

(c)

# Odvod diskretne funkcije

- Aproximacija odvoda zvezne funkcije



$$\frac{df}{du}(u) \approx \frac{f(u+1) - f(u-1)}{2} = 0.5 \cdot (f(u+1) - f(u-1))$$

# Gradient

---

- Parcialni odvodi:

$$\frac{\partial I}{\partial u}(u, v) \quad \text{and} \quad \frac{\partial I}{\partial v}(u, v)$$

- Gradient:

$$\nabla I(u, v) = \begin{bmatrix} \frac{\partial I}{\partial u}(u, v) \\ \frac{\partial I}{\partial v}(u, v) \end{bmatrix}$$

- Magnituda gradienta:

$$|\nabla I|(u, v) = \sqrt{\left(\frac{\partial I}{\partial u}(u, v)\right)^2 + \left(\frac{\partial I}{\partial v}(u, v)\right)^2}$$


- Rotacijsko invariantna

# Filtri z odvodi

- Aproksimacijo parcialnih odvod lahko računalmo z linearnimi filtri:

$$H_x^D = \begin{bmatrix} -0.5 & \mathbf{0} & 0.5 \end{bmatrix} = 0.5 \cdot \begin{bmatrix} -1 & \mathbf{0} & 1 \end{bmatrix}$$


$$H_y^D = \begin{bmatrix} -0.5 \\ \mathbf{0} \\ 0.5 \end{bmatrix} = 0.5 \cdot \begin{bmatrix} -1 \\ \mathbf{0} \\ 1 \end{bmatrix}$$



(a)



(b)



(c)



(d)

# Operatorji za iskanje robov

---

- Večina operatorjev za iskanje robov temelji na aproksimaciji lokalnega gradienta
  - Moč roba
  - Orientacija roba
- Različni (podobni) operatorji za iskanje robov
  - Prewittov in Sobelov operator
  - Robertsov operator
  - Operator Kompas
  - Cannyjev operator



# Prewittov operator

- Pred računanjem gradienta še malce zgladi okolico

$$H_x^P = \begin{bmatrix} -1 & 0 & 1 \\ -1 & \mathbf{0} & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad \text{and} \quad H_y^P = \begin{bmatrix} -1 & -1 & -1 \\ 0 & \mathbf{0} & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

$$H_x^P = \begin{bmatrix} 1 \\ \mathbf{1} \\ 1 \end{bmatrix} * \begin{bmatrix} -1 & \mathbf{0} & 1 \end{bmatrix} \quad \text{and} \quad H_y^P = \begin{bmatrix} 1 & \mathbf{1} & 1 \end{bmatrix} * \begin{bmatrix} -1 \\ \mathbf{0} \\ 1 \end{bmatrix}$$

- Gradient:

$$\nabla I(u, v) \approx \frac{1}{6} \cdot \begin{bmatrix} (I * H_x^P)(u, v) \\ (I * H_y^P)(u, v) \end{bmatrix}$$

# Sobelov operator

---

- Več poudarka na trenutno srednjo vrstico oz. stolpec pri glajenju:

$$H_x^S = \begin{bmatrix} -1 & 0 & 1 \\ -2 & \mathbf{0} & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad \text{and} \quad H_y^S = \begin{bmatrix} -1 & -2 & -1 \\ 0 & \mathbf{0} & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

- Gradient:

$$\nabla I(u, v) \approx \frac{1}{8} \cdot \begin{bmatrix} (I * H_x^S)(u, v) \\ (I * H_y^S)(u, v) \end{bmatrix}$$

# Moč in orientacija robov

- Rezultat filtriranja:

$$D_x(u, v) = H_x * I \quad \text{and} \quad D_y(u, v) = H_y * I$$

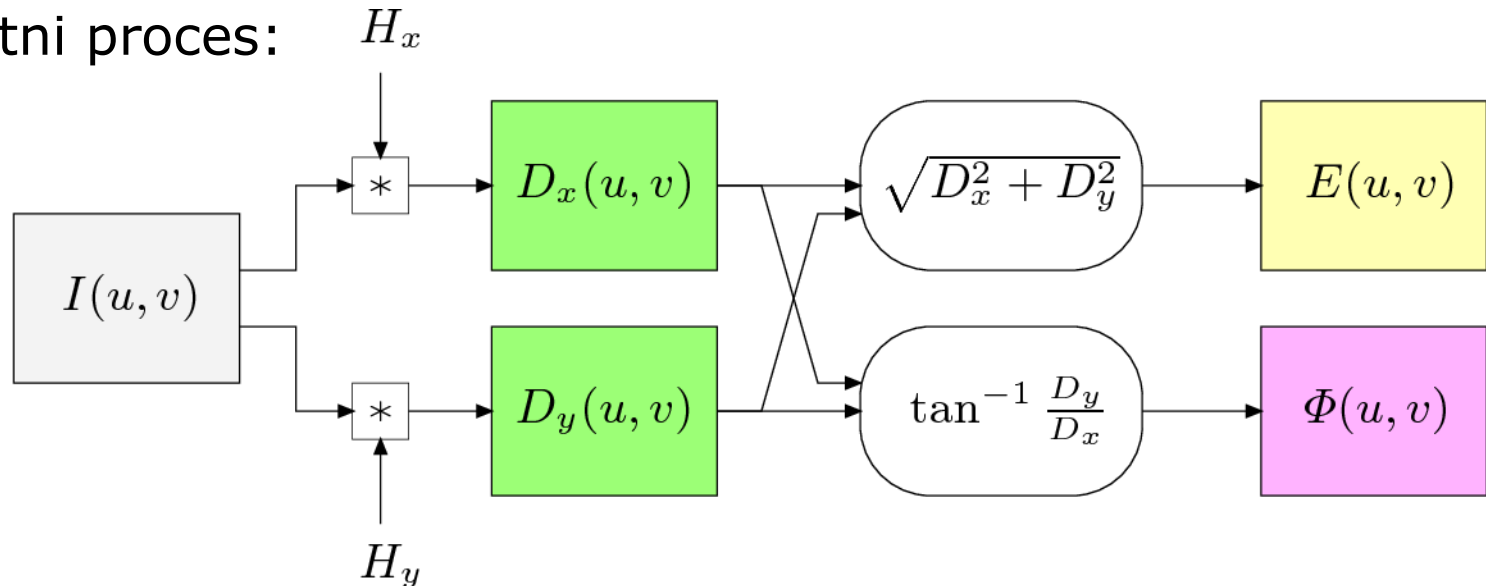
- Lokalna moč roba = magnituda gradienta

$$E(u, v) = \sqrt{(D_x(u, v))^2 + (D_y(u, v))^2}$$

- Lokalna orientacija roba:

$$\Phi(u, v) = \tan^{-1} \left( \frac{D_y(u, v)}{D_x(u, v)} \right) = \text{ArcTan}(D_x(u, v), D_y(u, v))$$

- Celotni proces:



# Izboljšani Sobelov operator

---


- Originalna Prewittov in Sobelov operator slabo ocenita orientacijo robov
- Izboljšani Sobelov operator:

$$H_x^{S'} = \frac{1}{32} \begin{bmatrix} -3 & 0 & 3 \\ -10 & \mathbf{0} & 10 \\ -3 & 0 & 3 \end{bmatrix} \quad \text{and} \quad H_y^{S'} = \frac{1}{32} \begin{bmatrix} -3 & -10 & -3 \\ 0 & \mathbf{0} & 0 \\ 3 & 10 & 3 \end{bmatrix}$$

# Robertsov operator

- Zelo enostaven in star


$$H_1^R = \begin{bmatrix} 0 & \mathbf{1} \\ -1 & 0 \end{bmatrix} \quad \text{and} \quad H_2^R = \begin{bmatrix} -1 & 0 \\ 0 & \mathbf{1} \end{bmatrix}$$



$$D_1 = I * H_1^R$$



$$D_2 = I * H_2^R$$



# Primerjava različnih operatorjev




Original



Roberts



Prewitt



Sobel

# Operator Kompas

- Filtri prilagojeni osmim orientacijam

$$\begin{aligned} H_0^K &= \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} & H_4^K &= \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix} \\ H_1^K &= \begin{bmatrix} -2 & -1 & 0 \\ -1 & 0 & 1 \\ 0 & 1 & 2 \end{bmatrix} & H_5^K &= \begin{bmatrix} 2 & 1 & 0 \\ 1 & 0 & -1 \\ 0 & -1 & -2 \end{bmatrix} \\ H_2^K &= \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} & H_6^K &= \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \\ H_3^K &= \begin{bmatrix} 0 & -1 & -2 \\ 1 & 0 & -1 \\ 2 & 1 & 0 \end{bmatrix} & H_7^K &= \begin{bmatrix} 0 & 1 & 2 \\ -1 & 0 & 1 \\ -2 & -1 & 0 \end{bmatrix} \end{aligned}$$

# Operator Kompas

- Aplikirati je potrebno samo štiri filtre:

$$I * H_4^K = I * -H_0^K = -(I * H_0^K)$$

$$\begin{array}{llll} D_0 \leftarrow I * H_0^K & D_1 \leftarrow I * H_1^K & D_2 \leftarrow I * H_2^K & D_3 \leftarrow I * H_3^K \\ D_4 \leftarrow -D_0 & D_5 \leftarrow -D_1 & D_6 \leftarrow -D_2 & D_7 \leftarrow -D_3 \end{array}$$

- Moč roba = maksimalnemu odzivu

$$\begin{aligned} E^K(u, v) &\triangleq \max(D_0(u, v), D_1(u, v), \dots, D_7(u, v)) \\ &= \max(|D_0(u, v)|, |D_1(u, v)|, |D_2(u, v)|, |D_3(u, v)|) \end{aligned}$$


- Orientacija roba = orientaciji filtra z maksimalnim odzivom:

$$\Phi^K(u, v) \triangleq \frac{\pi}{4} \quad \text{with } j = \operatorname{argmax}_{0 \leq i \leq 7} D_i(u, v)$$



# Drugi odvodi za detekcijo robov

- Včasih je rob težko lokalizirati na osnovi prvega odvoda
- Išče se ničla drugega odvoda



- Primer: LoG operator (Laplacian-of-Gaussian)

# Robovi na različnih skalah

---

- Človek gleda robove ne samo v zelo majhni okolici ampak v večjem kontekstu
  - Človek gleda robove na večih skalah
- => multiresolucijske tehnike za iskanje robov, ki iščejo robove na večih skalah

# Cannyjev operator

---

- Najbolj popularen operator
- Tri cilji:
  - Minimizirati število napačno detektiranih robnih točk
  - Dobra lokalizacija robov
  - Tanki robovi
- Uporablja prve odvode za detekcijo robov
- Uporablja druge odvode za tanjšanje robov (natančno lokalizacijo robov)
- Deluje na večih skalah (resolucijah slike)
  - Ali na eni skali s filtrom s prilagodljivim premerom
- Ponavadi daje najboljše rezultate


# Algoritem

---

1. Zmanjševanje šuma
  - Glajenje z Gaussovim filtrom
2. Računanje gradienta
  - Aplicira se linearni gradientni filter za iskanje robov (npr. Sobelov)
  - Izračuna se magnituda in smer roba (ki se zaokroži na enega od štirih kotov (0, 45, 90 in 135 stopinj))
  - Magnitude se upragovi, da dobimo sliko robov
3. Dušenje lokalnih ne-maximumov
  - Tanjšanje robov
  - Preveri velikosti magnitude dveh sosednjih elementov v smeri gradienta; če vrednost trenutnega slikovnega elementa ni največja, jo postavi na nič
4. Sledenje robov z uporagovljenjem na osnovi histerez
  - Rob se začne slediti, če je magnituda večja od T1 in se sledi vse dokler ni manjša od T2


# Primer – originalna slika

---




# Primer – zglaajena slika

---




# Primer – slika robov

---




# Primer – slika tankih robov





# Primer – končni rezultat




# Rezultati Cannyjevega operatorja



Original



$\sigma = 1.0$




$\sigma = 2.0$



$\sigma = 4.0$



$\sigma = 8.0$




$\sigma = 16.0$

# Primerjava različnih operatorjev



Original



Roberts



Prewitt



Sobel



Laplacian of Gaussian



Canny ( $\sigma = 1.0$ )

# Od robov do obrisov


---

- Enostavno sledenje robovom ponavadi ne deluje
  - Robovi se včasih končajo v regijah z majhnim gradientom
  - Robovi se sekajo
  - Obrisi se lahko vejajo v več smeri
- Lažje v enostavnih primerih in v primeru binarnih slik
- Zemljevid robov
  - Če je izhod operatorja za iskanje robov sivinska slika, jo upragovimo in dobimo sliko robov (edge map)
    - Globalno upragovljenje
      - Ne najboljše, prekinjene črte, ipd.
      - Dovolj dobro za nekatere vrste nadaljnjega procesiranja (Houghova transformacija)
    - Lokalno upragovljenje
      - Na osnovi histerez (Canny)

# Ostrenje robov

- Robove lahko poudarimo  
-> poudarimo visokofrekvenčne dele slike
- Odštejemo skalirano vrednost drugega odvoda

$$\check{f}(x) = f(x) - w \cdot f''(x)$$



# Laplaceov operator

- Laplaceov operator je vsota vrednosti drugih parcialnih odvodov:

$$(\nabla^2 f)(x, y) = \frac{\partial^2 f}{\partial^2 x}(x, y) + \frac{\partial^2 f}{\partial^2 y}(x, y)$$

- Računamo ga z linearnimi filtri:

$$\frac{\partial^2 f}{\partial^2 x} \equiv H_x^L = \begin{bmatrix} 1 & -2 & 1 \end{bmatrix} \quad \text{and} \quad \frac{\partial^2 f}{\partial^2 y} \equiv H_y^L = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$$

- Oz, ker  $I * H^L = I * (H_x^L + H_y^L) = (I * H_x^L) + (I * H_y^L)$

- je Laplaceov filter:

$$H^L = H_x^L + H_y^L = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

oziroma:

$$H_8^L = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$
$$H_{12}^L = \begin{bmatrix} 1 & 2 & 1 \\ 2 & -12 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

# Učinek Laplaceovega operatorja




(a)



(b)



(c)



(d)


# Ostrenje

- Laplaceov operator + odštevanje od originalne slike:


$$\check{I} \leftarrow I - w \cdot (H^L * I)$$




(a)



(b)




(c)



(d)



(e)



(f)



# Ostrenje z neostro masko (USM filter)

- Znano iz analogne fotografije:
  1. Generiraj neostro masko (z Gaussovim filtrom):

$$M \leftarrow I - (I * \tilde{H}) = I - \tilde{I}$$

2. Prištej skalirano masko originalni sliki:

$$\check{I} \leftarrow I + a \cdot M$$

$$\check{I} \leftarrow I + a \cdot (I - \tilde{I}) = (1 + a) \cdot I - a \cdot \tilde{I}$$

- Ostri tudi šum v homogenih regijah
- Razširitev: ostrenje samo kjer je lokalni kontrast dovolj velik:

$$\check{I}(u, v) \leftarrow \begin{cases} I(u, v) + a \cdot M(u, v) & \text{for } |\nabla I|(u, v) \geq t_c \\ I(u, v) & \text{otherwise.} \end{cases}$$


# Učinek USM filtra



(a) Original



(b)




(c)



(d)  $\sigma = 2.5$



(e)




(f)



(g)  $\sigma = 10.0$



(h)



(i)

# Laplaceov proti USM filtru

- Ostrenje z Laplaceovim filtrom je poseben primer USM filtra s filtrom za glajenje:

$$\tilde{H} = \tilde{H}^L = \frac{1}{5} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\begin{aligned} H^L &= \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix} - 5 \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \\ &= 5 \left( \frac{1}{5} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 0 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \right) = 5 (\tilde{H} - \delta) \end{aligned}$$

$$\begin{aligned} \check{I}_L &\leftarrow I - w \cdot (H^L * I) = I - w \cdot (5(\tilde{H}^L - \delta) * I) \\ &= I - 5w \cdot (\tilde{H}^L * I - I) = I + 5w \cdot (I - \tilde{H}^L * I) \\ &= I + 5w \cdot M^L \end{aligned}$$

# Detekcija kotov

---

- Koti so zelo pomembni, izstopajoči strukturni elementi na slikah
- So robustni:
  - Se ne pojavljajo naključno
  - So ponovljivi
  - Se jih da robustno zaznati
    - na različnih slikah
    - zajetimi pod različnimi koti
    - v različnih svetlobnih pogojih
    - na različnih razdaljah
- Detekcija kotov se zelo pogosto uporablja:
  - Za sledenje predmetom
  - Za ugotavljanje korespondence med stereo pari slik
  - Kot referenčne točke za natančne geometrične meritve
  - Za kalibracijo sistemov kamer za strojni vid
  - Za ugotavljanje ujemanja med slikami
  - Za iskanje točk kjer se aplicirajo bolj zahtevni operatorji

# Zanimive točke

---

- Koti so zelo primerni za iskanje zanimivih točk (points of interest)
- Zahtevane lastnosti za detektor kotov:
  - Razlikovanje med pravimi in slučajnimi koti
  - Zanesljivost ob prisotnosti šuma
  - Natančno določanje lokacije kota
  - Učinkovita implementacija
- Kot je lokacija na sliki, kjer je gradient velik v več smereh hkrati
  - Večina metod za detekcijo kotov temelji na procesiranju prvih in drugih parcialnih odvodov

# Harrisov detektor robov

---

- Matrika lokalne strukture
  - Temelji na prvih parcialnih odvodih

$$I_x(u, v) = \frac{\partial I}{\partial x}(u, v) \quad \text{and} \quad I_y(u, v) = \frac{\partial I}{\partial y}(u, v)$$

$$A(u, v) = I_x^2(u, v)$$

$$B(u, v) = I_y^2(u, v)$$

$$C(u, v) = I_x(u, v) \cdot I_y(u, v)$$

$$\mathbf{M} = \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix} = \begin{pmatrix} A & C \\ C & B \end{pmatrix}$$

# Harrisov detektor robov

- Glajenje elementov matrike lokalne strukture

$$\bar{M} = \begin{pmatrix} A * H^{G,\sigma} & C * H^{G,\sigma} \\ C * H^{G,\sigma} & B * H^{G,\sigma} \end{pmatrix} = \begin{pmatrix} \bar{A} & \bar{C} \\ \bar{C} & \bar{B} \end{pmatrix}$$

- Diagonalizacija

$$\bar{M}' = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$$

$$\begin{aligned} \lambda_{1,2} &= \frac{\text{trace}(\bar{M})}{2} \pm \sqrt{\left(\frac{\text{trace}(\bar{M})}{2}\right)^2 - \det(\bar{M})} \\ &= \frac{1}{2} \left( \bar{A} + \bar{B} \pm \sqrt{\bar{A}^2 - 2\bar{A}\bar{B} + \bar{B}^2 + 4\bar{C}^2} \right) \end{aligned}$$

- Lastne vrednosti vsebujejo zelo pomembno informacijo o lokalni strukturi slike
  - Če sta obe dovolj veliki (sta si podobni) je verjetnost za kot velika

# Harrisov detektor robov

- Funkcija odziva na kote (Corner Response Function – CRF)
  - Temelji na razliki med lastnima vrednostima

$$\lambda_1 - \lambda_2 = 2 \cdot \sqrt{\frac{1}{4} \cdot (\text{trace}(\bar{M}))^2 - \det(\bar{M})}$$


- Mera za jakost kota:

$$\begin{aligned} Q(u, v) &= \det(\bar{M}) - \alpha \cdot (\text{trace}(\bar{M}))^2 \\ &= (\bar{A}\bar{B} - \bar{C}^2) - \alpha \cdot (\bar{A} + \bar{B})^2 \end{aligned}$$


- Parameter  $\alpha$  določa občutljivost detektorja
  - Večji kot je, manj občutljiv je detektor, manj kotov je detektiranih
- Določanje kotov
  - Izberejo se točke z  $Q(u, v) > t_H$
  - Dobimo seznam točk  $\text{Corners} = [\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_N]$
  - Seznam sortiramo po močeh kotov  $Q(u, v)$  ohranimo samo najmočnejše v vsaki oolici




# Ilustrativni primer




$I(u, v)$




$A = I_x^2(u, v)$




$B = I_y^2(u, v)$



$C = I_x I_y(u, v)$



$Q(u, v)$



detected corners

# Algoritem

1: HARRISCORNERS( $I$ )

Returns a list of the strongest corners found in the image  $I$ . **Prefilter** (line 3): Smoothing with a small  $xy$ -separable filter  
 $H_p = H_{px} * H_{py}$ , where

2: STEP 1—COMPUTE THE CORNER RESPONSE FUNCTION:

3: Prefilter (smooth) the original image:  $I' \leftarrow I * H_p$   $\leftarrow H_{px} = \frac{1}{9} \begin{bmatrix} 2 & 5 & 2 \end{bmatrix}$  and  $H_{py} = H_{px}^T = \frac{1}{9} \begin{bmatrix} 2 \\ 5 \\ 2 \end{bmatrix}$ .

4: Compute the horizontal and vertical image derivatives:

$$I_x \leftarrow I' * H_{dx}$$

$$I_y \leftarrow I' * H_{dy}$$

**Gradient filter** (line 4): Computing the first partial derivative in the  $x$  and  $y$  directions with

5: Compute the local structure matrix  $M(u, v) = \begin{pmatrix} A & C \\ C & B \end{pmatrix}$ :

$$A(u, v) \leftarrow I_x^2(u, v)$$

$$B(u, v) \leftarrow I_y^2(u, v)$$

$$C(u, v) \leftarrow I_x(u, v) \cdot I_y(u, v)$$

$$H_{dx} = \begin{bmatrix} -0.453014 & 0 & 0.453014 \end{bmatrix} \quad \text{and} \quad H_{dy} = H_{dx}^T = \begin{bmatrix} -0.453014 \\ 0 \\ 0.453014 \end{bmatrix}$$

6: Blur each component of the structure matrix:  $\bar{M} = \begin{pmatrix} \bar{A} & \bar{C} \\ \bar{C} & \bar{B} \end{pmatrix}$ :

$$\bar{A} \leftarrow A * H_b$$

$$\bar{B} \leftarrow B * H_b$$

$$\bar{C} \leftarrow C * H_b$$

**Blurfilter** (line 6): Smoothing the individual components of the structure matrix  $M$  with separable Gaussian filters  $H_b = H_{bx} * H_{by}$

7: Compute the corner response function:

$$Q \leftarrow (\bar{A} \cdot \bar{B} - \bar{C}^2) - \alpha \cdot (\bar{A} + \bar{B})^2$$

$$H_{bx} = \frac{1}{64} \begin{bmatrix} 1 & 6 & 15 & 20 & 15 & 6 & 1 \end{bmatrix}, \quad H_{by} = H_{bx}^T = \frac{1}{64} \begin{bmatrix} 1 \\ 6 \\ 15 \\ 20 \\ 15 \\ 6 \\ 1 \end{bmatrix}$$

8: STEP 2—COLLECT CORNER POINTS:

9: Create an empty list:

$$Corners \leftarrow []$$

10: **for** all image coordinates  $(u, v)$  **do**

11: **if**  $Q(u, v) > t_H$  **and** ISLOCALMAX( $Q, u, v$ ) **then**

12: Create a new corner:

$$c_i \leftarrow \langle u_i, v_i, q_i \rangle = \langle u, v, Q(u, v) \rangle$$

Add  $c_i$  to  $Corners$

**Steering parameter** (line 7):  $\alpha = 0.04$  to  $0.06$  (default  $0.05$ )

**Response threshold** (line 13):  $t_H = 10,000$  to  $1,000,000$  (default  $25,000$ )

13: **Sort**  $Corners$  by  $q_i$  in *descending* order (strongest corners first)

14:  $GoodCorners \leftarrow \text{CLEANUPNEIGHBORS}(Corners)$

15: **return**  $GoodCorners$ .

# Algoritem

---


```
17: IsLOCALMAX( $Q, u, v$ )      ▷ determine if  $Q(u, v)$  is a local maximum
18:   Let  $q_c \leftarrow Q(u, v)$  (center pixel)
19:   Let  $\mathcal{N} \leftarrow Neighbors(Q, u, v)$       ▷ values of all neighboring pixels
20:   if  $q_c \geq q_i$  for all  $q_i \in \mathcal{N}$  then
21:     return true
22:   else
23:     return false.

24: CLEANUPNEIGHBORS( $Corners$ )  ▷  $Corners$  is sorted by descending  $q$ 
25:   Create an empty list:
      $GoodCorners \leftarrow []$ 
26:   while  $Corners$  is not empty do
27:      $c_i \leftarrow REMOVEFIRST(Corners)$ 
28:     Add  $c_i$  to  $GoodCorners$ 
29:     for all  $c_j$  in  $Corners$  do
30:       if  $Dist(c_i, c_j) < d_{min}$  then ← Neighborhood radius (line 31):  $d_{min} = 10$  pixels
31:         Delete  $c_j$  from  $Corners$ 
32:   return  $GoodCorners$ .
```


# Primer




(a)




(b)



(c)



(d)



(e)